Prof. Dr. Luis Filipe Alves Pereira
Curso: Aprendizagem de Máquina
2026

feature ENGINEERING

Em um projeto real de Machine Leaning,
muito trabalho é realizado **antes do uso de um algoritmo de aprendizado**

(atividades do engenheiro de dados)

Em um projeto real de Machine Leaning,
Quando tranbalhamos com bases **muito grandes (ex.: 2TB)**, não podemos carregar **todos os dados em memória** para usar um **algoritmo de aprendizado**

hadoop

APACHE Spark™

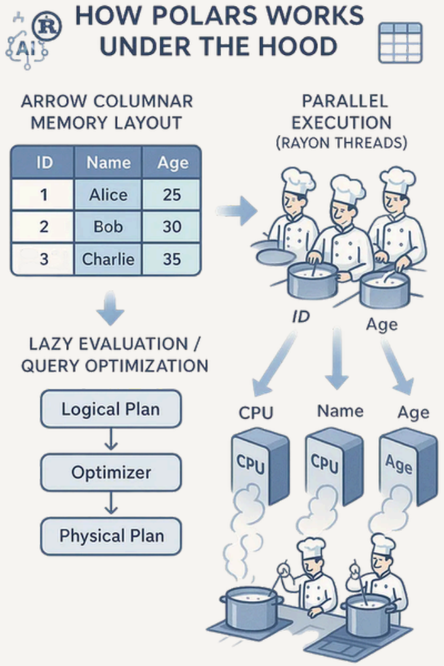

Polars

(ferramentas do engenheiro de Big Data)

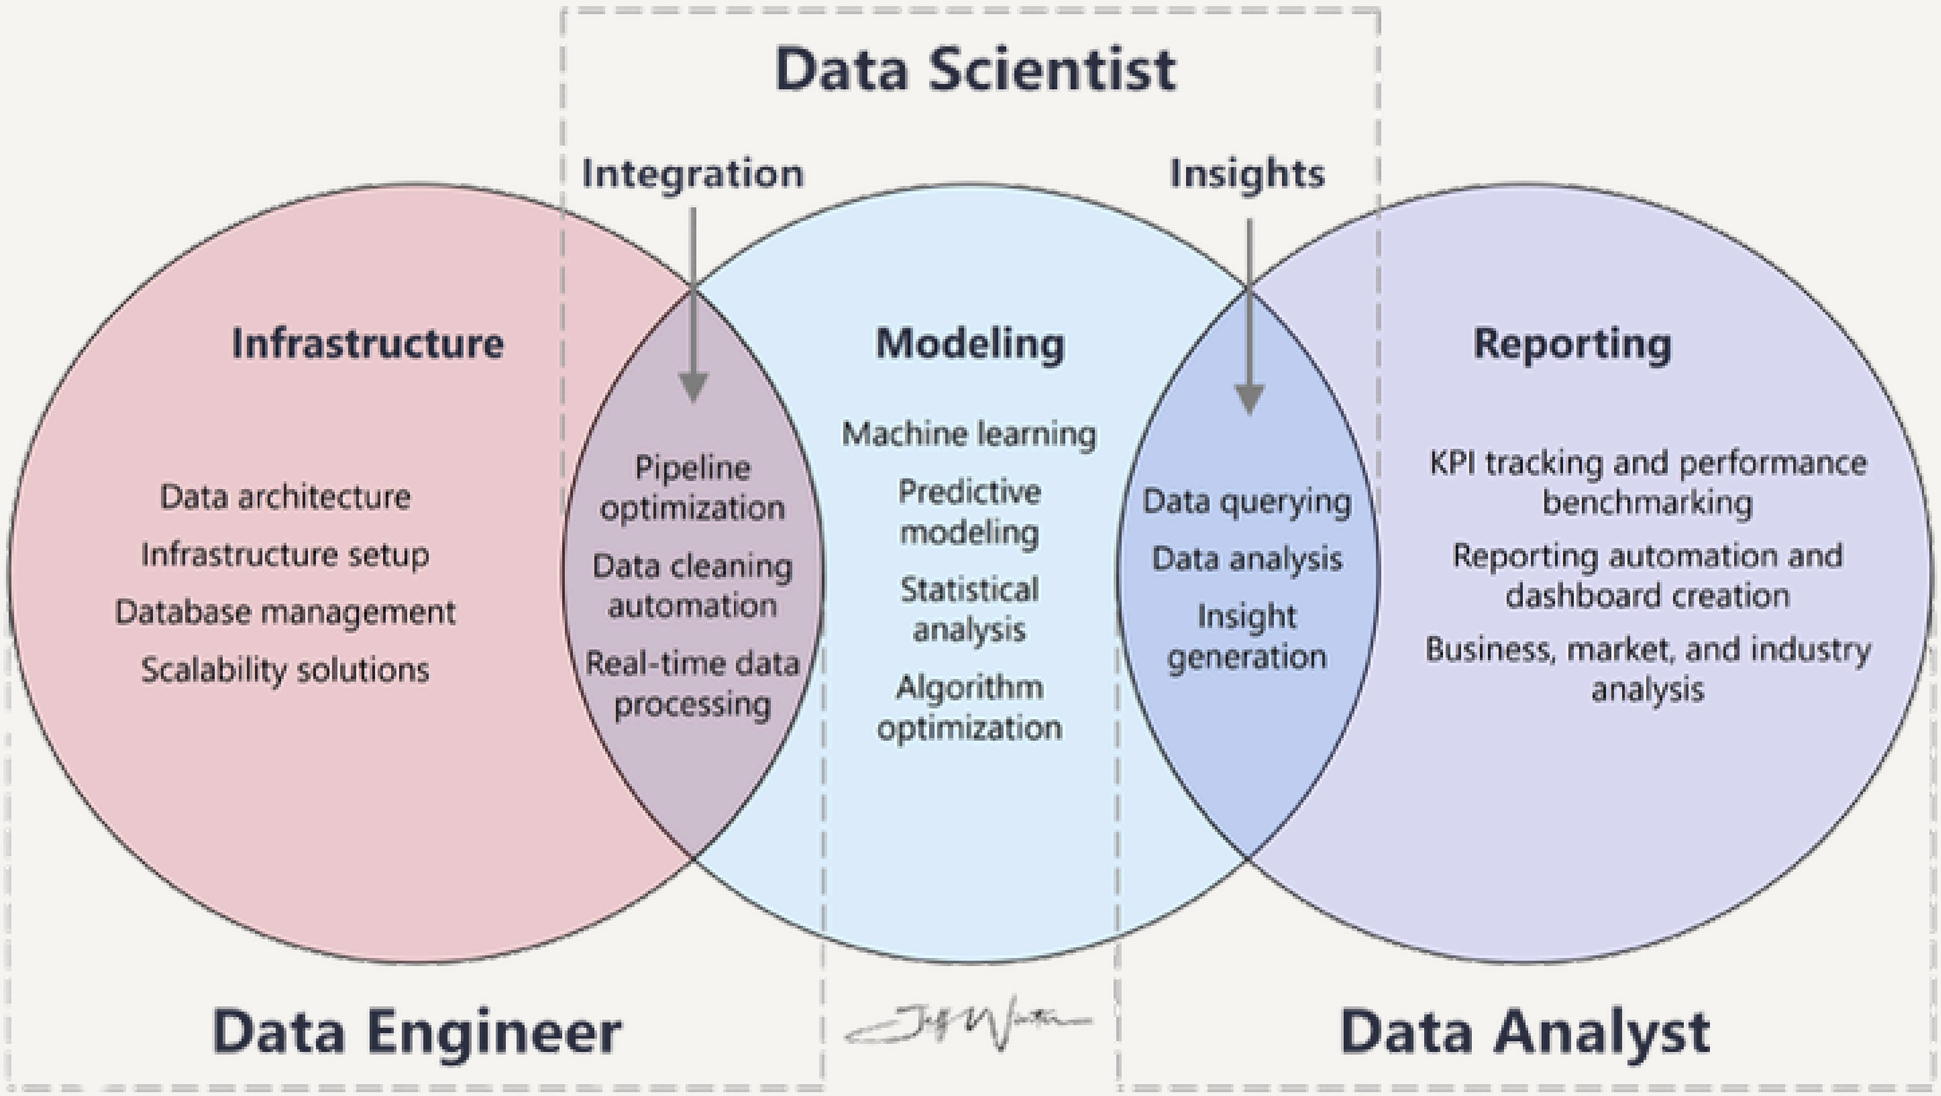

Adaptation of the data science diagram created by Kevin Schmidt in Towards Data Science, 2015

Kevin Schmidt

ML at Instagram, former CTO Century Tech, former head data cruncher at Mind Candy and Last.fm, Speaker at O'Reilly Strata and Nucl.AI. My writing is also at https://medium.com/@KevinSchmidtBiz

THE DATA SCIENCE HIERARCHY OF NEEDS

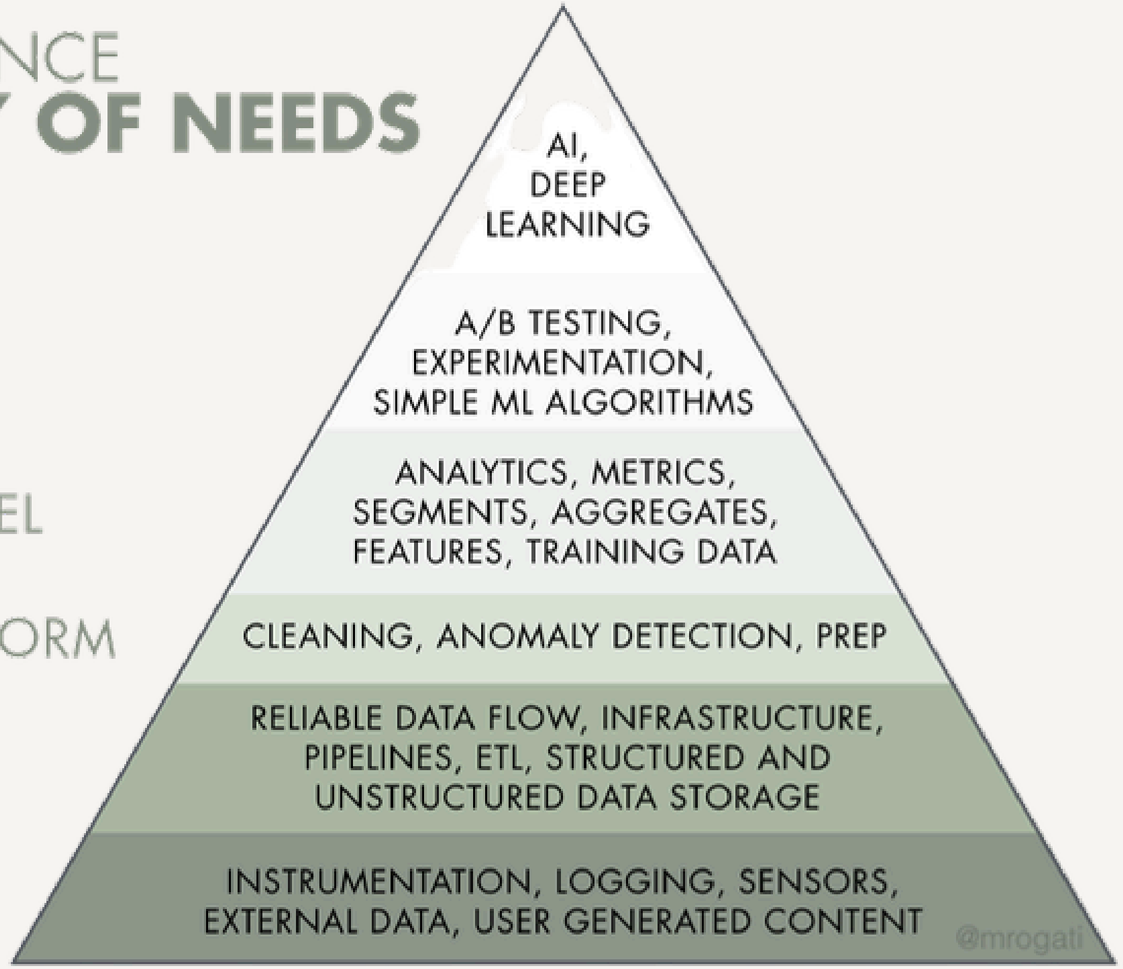

LEARN/OPTIMIZE

AGGREGATE/LABEL

EXPLORE/TRANSFORM

MOVE/STORE

COLLECT

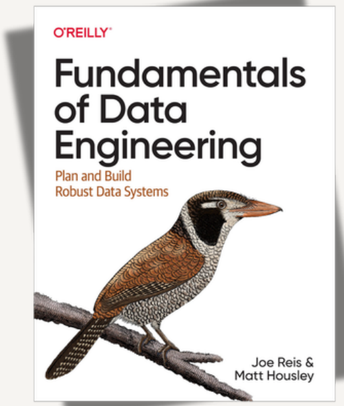

matillion

What is ETL? A Simple Guide to Extract, Transform, Load

ETL stands for Extract, Transform, Load — a process that moves data from various sources into a centralized data warehouse or platform, making it clean, reliable, and analytics-ready.

Extract

What happens?

Data is pulled from source systems.

Examples: CRMs, ERPs, APIs, flat files, IoT sensors.

Goal

Collect raw data without losing fidelity.

Transform

What happens?

Data is cleaned, formatted, and enriched

Common actions:

Filtering duplicates
Standardizing formats
Joining multiple datasets
Adding calculated fields

Goal

Make data usable and trustworthy.

Load

What happens?

Transformed data is loaded into a target system (typically a data warehouse or lake).

Goal

Make data available for analytics, BI, and AI.

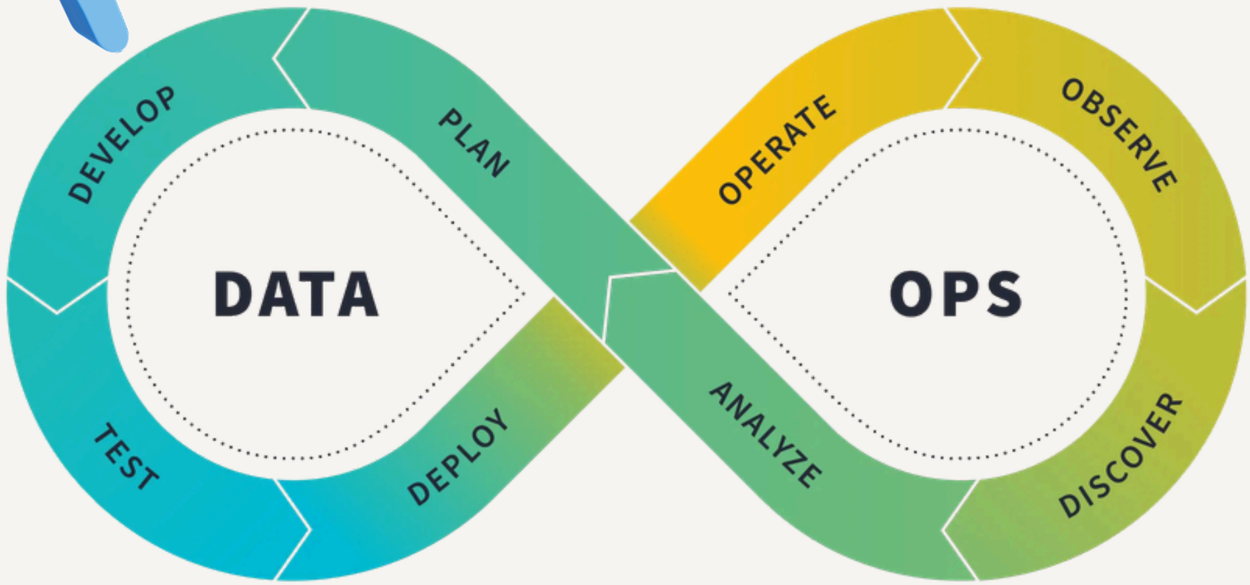

tx_id	cliente_id	ts	valor	tipo_chave	canal	dist_km_ult_local	novo_dispositivo	troca_sim_24h	tentativas_login_1h	idade_conta_dias	qtd_pix_24h	valor_total_pix_24h	tempo_desde_ult_tx_min	idade_conta_dest_dias	qtd_recebimentos_1h_dest	risco_dest_score	fraude
TX0001	C0007	2026-02-20 10:14:22	45.9	telefone	app	1.2	0	0	1	860	3	220.4	180	1200	2	12	0
TX0002	C0012	2026-02-20 23:48:10	980	aleatoria	app	18	0	0	1	420	6	1350	12	900	3	25	0
TX0003	C0044	2026-02-21 02:13:51	3200	aleatoria	app	520.4	1	1	6	12	1	3200	9999	2	18	92	1
TX0004	C0044	2026-02-21 02:16:08	2500	aleatoria	app	521	1	1	7	12	2	5700	2	2	22	95	1
TX0005	C0103	2026-02-19 15:02:09	79.99	email	web	3.7	0	0	1	1400	2	159.98	600	3000	1	8	0
TX0006	C0020	2026-02-21 08:40:33	150	cpf	app	0.8	0	0	2	75	9	890	5	3650	1	10	0
TX0007	C0999	2026-02-21 09:11:02	1200	telefone	app	210.3	1	0	4	20	1	1200	1440	5	25	88	1
TX0008	C0231	2026-02-20 12:22:47	35	cpf	app	2	0	0	1	300	5	120	90	800	1	9	0
TX0009	C0231	2026-02-20 12:24:05	39	cpf	app	2	0	0	1	300	6	159	1	800	1	9	0
TX0010	C0777	2026-02-18 21:55:19	4999.9	aleatoria	app	1100	1	1	8	8	1	4999.9	9999	1	40	98	1
TX0011	C0505	2026-02-21 14:31:44	260	cnpj	web	7.9	0	0	1	1100	4	980	30	2600	2	18	0
TX0012	C0505	2026-02-21 14:33:02	270	cnpj	web	7.9	0	0	1	1100	5	1250	1	2600	2	18	0
TX0013	C0133	2026-02-21 05:02:17	890	telefone	app	12.5	0	0	2	600	2	910	720	400	4	30	0
TX0014	C0133	2026-02-21 05:04:55	3100	aleatoria	app	12.5	0	0	2	600	3	4010	2	400	10	72	1

Considere:

$$y = 1 : \text{classe pix fraude}$$
$$y = 0 : \text{classe pix legitimo}$$

Vimos que a regressão logística assume que:

$$\hat{p}(y = 1 \mid \mathbf{x}; \theta) = \frac{1}{1 + e^{-\theta^T \mathbf{x}}}$$

Nesse caso, como representar uma observação em um vetor $\mathbf{x} \in \mathbb{R}^d$?

Nos casos de atributos numéricos (ex.: idade_conta_dias)

$$x'_n = \frac{x_n - \mu_n}{\sigma_n}$$

(dados padronizados com média zero e devio padrão um)

$$x'_n = \frac{x_n - x_n^{min}}{x_n^{max} - x_n^{min}}$$

(dados normalizados entre zero e um)

Considere, por exemplo:

$$x_1 : \texttt{idade_conta_dias}, \qquad x_2 : \texttt{qtd_pix_24h}.$$

Na base observamos:

$$x_1 \in [0, 3000] \quad (\text{dias}), \qquad x_2 \in [0, 50] \quad (\text{transacoes em 24h}).$$

Suponha os pesos iniciais da regressão logística:

$$\theta_0 = -0.05, \qquad \theta_1 = -0.01, \qquad \theta_2 = 0.1,$$

Considere o processamendo da observação $\mathbf{x} = \begin{bmatrix} 2000 \\ 10 \end{bmatrix}$

$$\theta^T \mathbf{x} = -0.05 + (-0.01 \cdot 2000) + (0.10 \cdot 10) = -0.05 - 20 + 1 = -19.05$$

(a idade_conta_dias dominou completamente a saída do modelo!!!)

Nos casos de atributos categóricos (ex.: tipo_chave)

$$\mathcal{C} \;=\; \{\texttt{cpf}, \texttt{cnpj}, \texttt{telefone}, \texttt{email}, \texttt{aleatoria}\}, \qquad |\mathcal{C}| = K = 5.$$

Originalmente: $$x_5 \;=\; \texttt{tipo_chave} \;\in\; \mathcal{C}$$

$$\boldsymbol{\phi}(x_5) = \begin{bmatrix} 1 \;\; \texttt{if} \;\; x_5 = \texttt{cpf}, 0 \;\; \texttt{otherwise} \\ 1 \;\; \texttt{if} \;\; x_5 = \texttt{cnpj}, 0 \;\; \texttt{otherwise} \\ 1 \;\; \texttt{if} \;\; x_5 = \texttt{telefone}, 0 \;\; \texttt{otherwise} \\ 1 \;\; \texttt{if} \;\; x_5 = \texttt{email}, 0 \;\; \texttt{otherwise} \\ 1 \;\; \texttt{if} \;\; x_5 = \texttt{aleatoria}, 0 \;\; \texttt{otherwise} \end{bmatrix} \in \{0,1\}^K, \qquad \sum_{k=1}^{K} \phi_k(x_5) = 1.$$

$$x_5^{(232)} = \texttt{telefone} \quad \Longrightarrow \quad \boldsymbol{\phi}(x_5^{(232)}) = \begin{bmatrix} 0 \\ 0 \\ 1 \\ 0 \\ 0 \end{bmatrix}.$$

Considere agora:

x_1 : `idade_conta_dias`, x_2 : `qtd_pix_24h` x_3 : `tipo_chave`

$$\mathbf{x}^{(232)} = \begin{bmatrix} 1 \\ 361 \\ 4 \\ \texttt{email} \end{bmatrix}$$

(padronização dos atributos numéricos)

$$\mu_{x_1} = 221, \qquad \sigma_{x_1} = 80$$

$$\mu_{x_2} = 5, \qquad \sigma_{x_2} = 3$$

$$x_1' = \frac{361 - 221}{80} = 1.76$$

$$x_2' = \frac{4 - 3}{3} = 0.33$$

$$\mathbf{x}^{(232)} = \begin{bmatrix} 1 \\ 1.76 \\ 0.33 \\ \texttt{email} \end{bmatrix}$$

(one-hot-encoding de atributos categóricos)

$$\mathbf{x}^{(232)} = \begin{bmatrix} 1 \\ 1.76 \\ 0.33 \\ \phi(\texttt{email}) \end{bmatrix} = \begin{bmatrix} 1 \\ 1.76 \\ 0.33 \\ 0 \\ 0 \\ 0 \\ 1 \\ 0 \end{bmatrix}$$

“... muitas empresas com as quais trabalhei constataram por repetidas vezes que, com um modelo viável, **features adequadas costumam dar um maior aumento de desempenho** em comparação às técnicas algorítimicas inteligentes, como o ajuste de hiperparâmetros...’

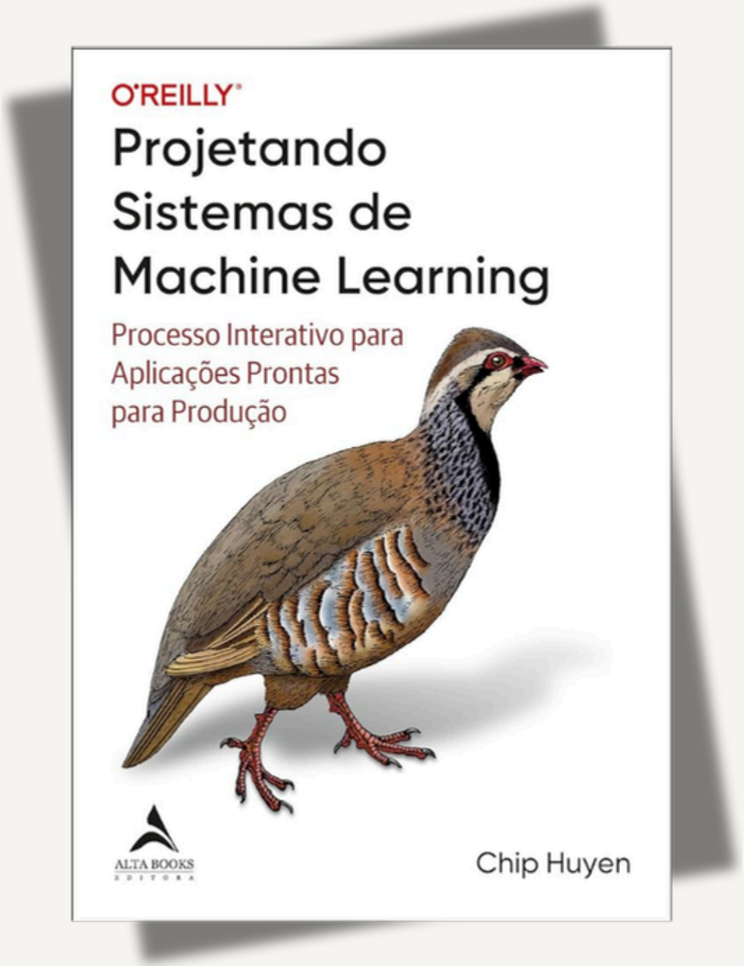

“A promessa do apendizado profundo é não precisarmos criar features manuais... No entanto, **estamos bem longe** do ponto em que poderemos **automatizar totalmente a descoberta de novas features**.’

Novo atributo que indica fim de semana:

```
df["is_fds"] = pd.to_datetime(df["ts"]).dt.dayofweek.isin([5, 6]).astype(int)
```

Novo atributo que indica madrugada:

```
df["is_madrugada"] = pd.to_datetime(df["ts"]).dt.hour.between(0, 5).astype(int)
```

Novo atributo que indica a faixa do valor transacionado:

```
bins = [-float("inf"), 50, 200, 1000, float("inf")]
labels = ["0-50", "50-200", "200-1000", "1000+"]
df["faixa_valor"] = pd.cut(df["valor"], bins=bins, labels=labels, right=False)
```

Novo atributo que considera um novo dispositivo e o valor transacionado:

```
df["combo_dispositivo_x_log_valor"] = ( (df["novo_dispositivo"].eq(1) & df["troca_sim_24h"].eq(1)).astype(int) * np.log1p(df["valor"]) )
```

Como identificar uma boa feature?

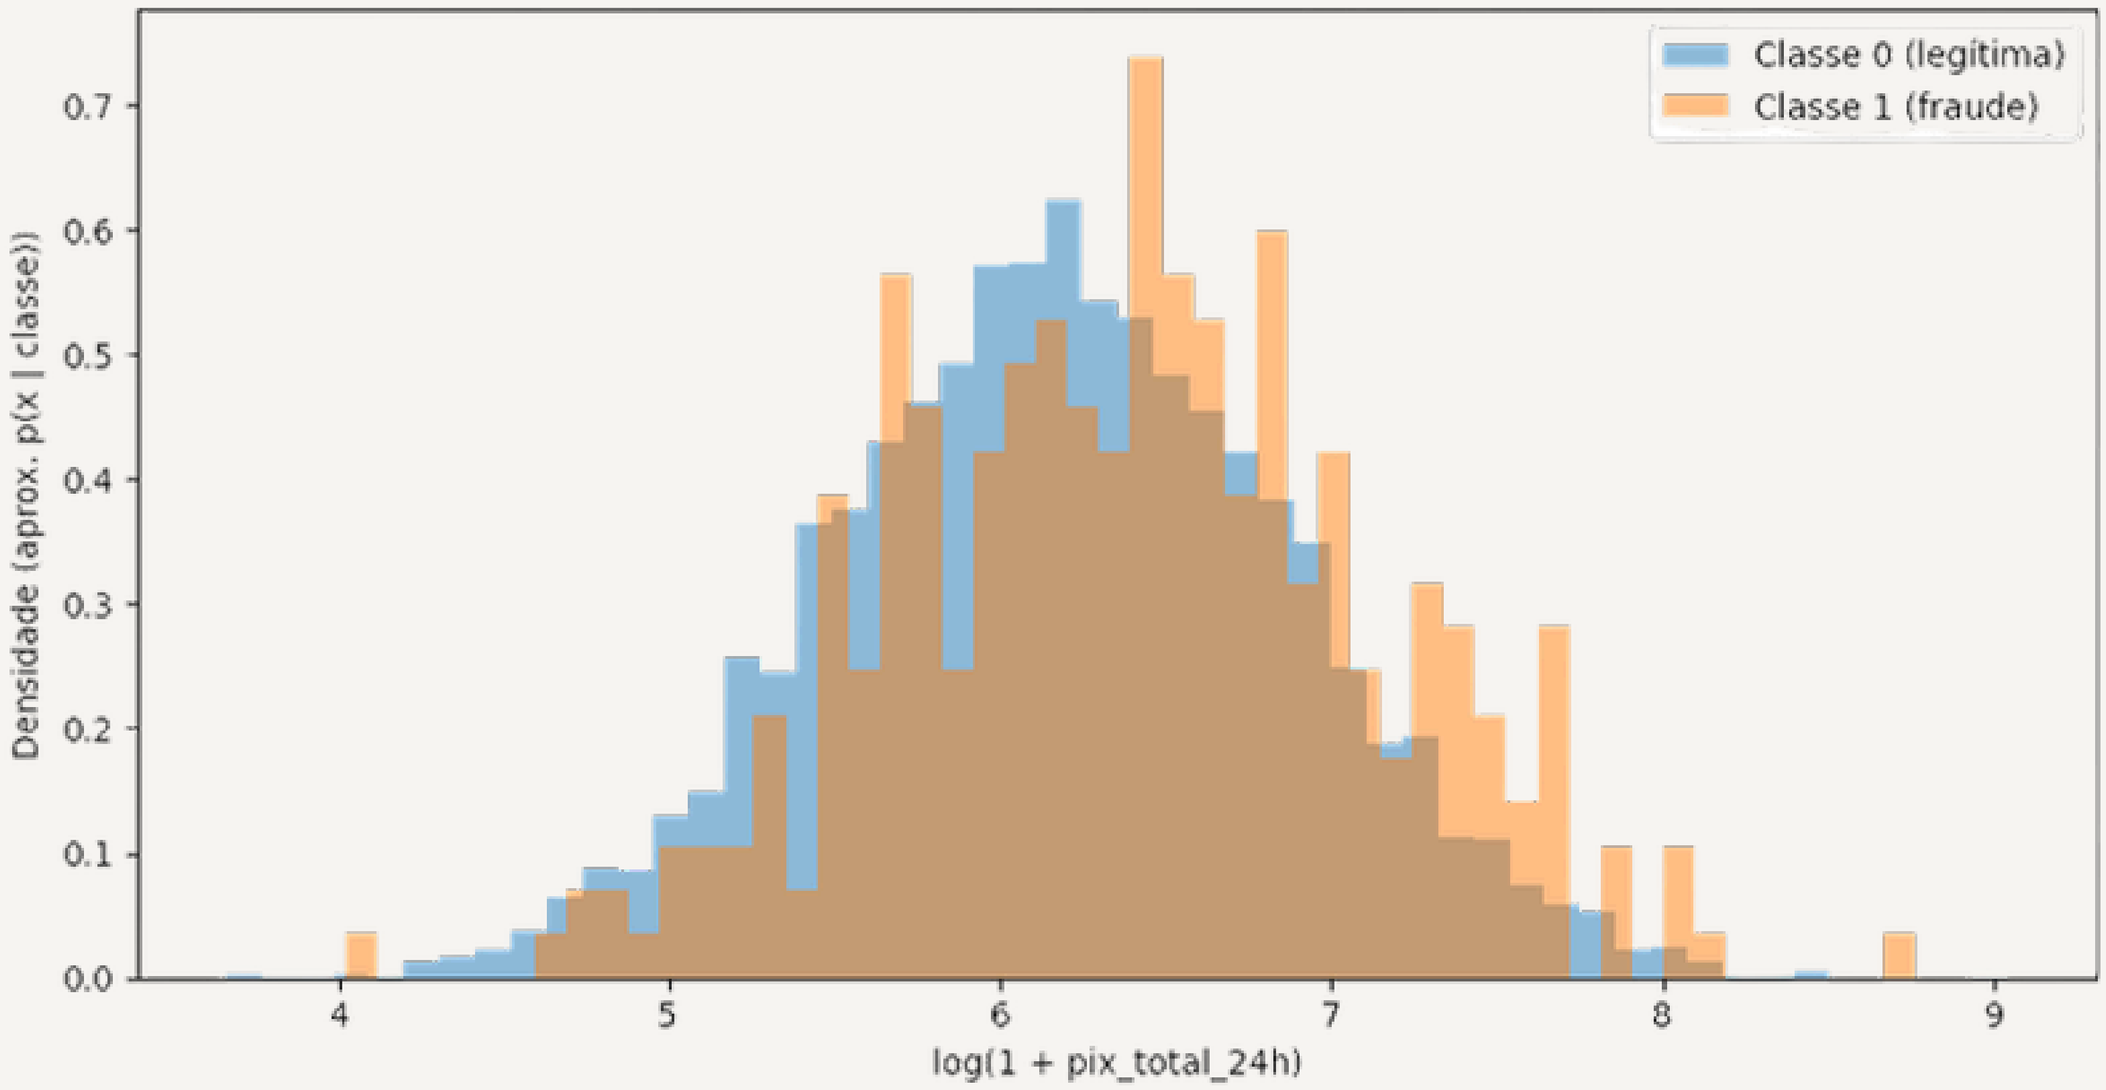

Como identificar uma boa feature?

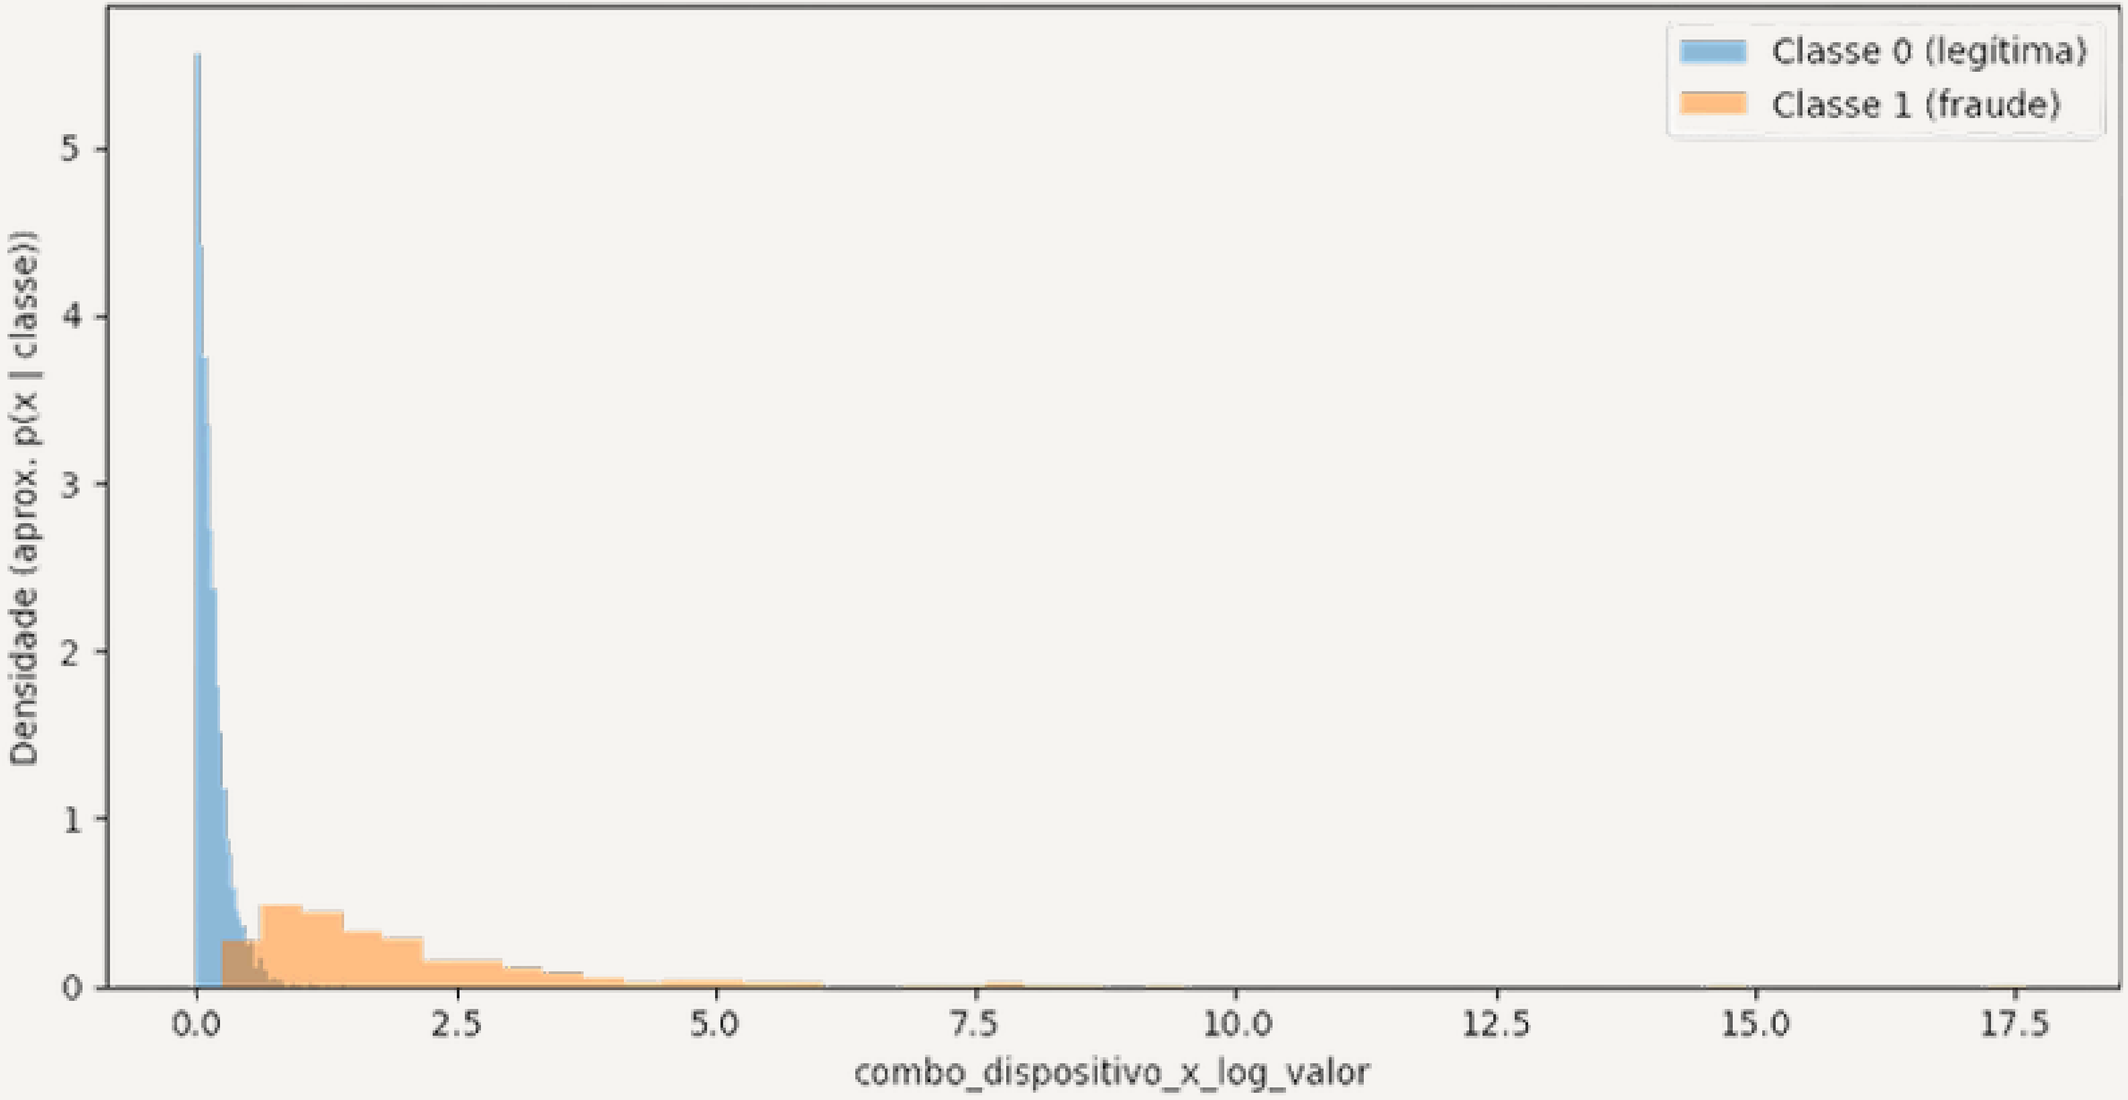

Aprendizagem de Máquina baseada em Kernels

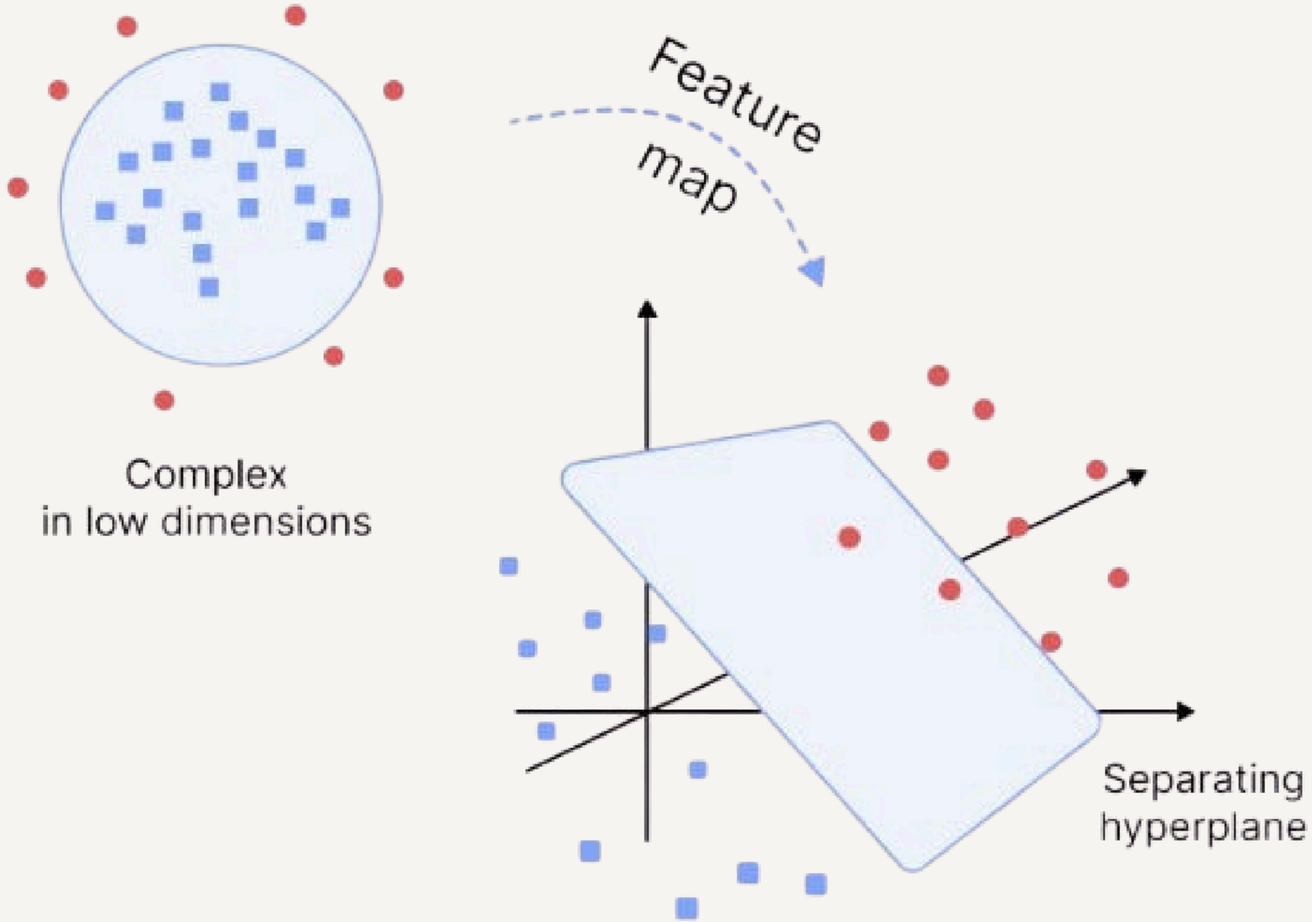

existe outro espaço de features onde a classificação é mais fácil?

O aprendizado/predição está relacionado à similaridade entre vetores: **produto interno**

$$\phi : \mathcal{X} \to \mathcal{H}, \qquad \mathbf{x} \mapsto \phi(\mathbf{x}).$$

$$k(\mathbf{x}, \mathbf{y}) \triangleq \langle \phi(\mathbf{x}), \phi(\mathbf{y}) \rangle$$

$$< v, u >= cos\varphi.|v|.|u|$$

$$cos\varphi = \frac{< v, u >}{|v|.|u|}$$

Entao, ao inves de construir $\phi(\cdot)$ explicitamente, computamos diretamente $k(\mathbf{x}, \mathbf{y})$

Para o conjunto de treino $\{\mathbf{x}_i\}_{i=1}^n$:

$$K \in \mathbb{R}^{n \times n}, \qquad K_{ij} = k(\mathbf{x}_i, \mathbf{x}_j)$$

$Ex.:$

$$K = \begin{bmatrix} 1.00 & 0.62 & -0.15 & 0.40 & 0.05 \\ 0.62 & 1.00 & 0.18 & 0.55 & -0.10 \\ -0.15 & 0.18 & 1.00 & -0.22 & 0.30 \\ 0.40 & 0.55 & -0.22 & 1.00 & 0.12 \\ 0.05 & -0.10 & 0.30 & 0.12 & 1.00 \end{bmatrix} \quad \text{onde } K_{ij} = k(\mathbf{x}_i, \mathbf{x}_j)$$

$$K_{1,3} = k(\mathbf{x}_1, \mathbf{x}_3) = -0.15$$

$$k(\mathbf{x}_1, \mathbf{x}_3) = \langle \phi(\mathbf{x}_1), \phi(\mathbf{x}_3) \rangle = -0.15$$

Um kernel válido gera uma matriz semidefinida positiva:

$$K = K^\top, \qquad \mathbf{a}^\top K\,\mathbf{a} \geq 0,\ \forall\,\mathbf{a} \in \mathbb{R}^n,$$

$$\text{Todos os auvtovalores de } K \text{ sao } \geq 0$$

kernel polinomial:

$$k(\mathbf{x}, \mathbf{z}) = (\mathbf{x}^\top \mathbf{z} + c)^p, \quad c \geq 0,\ p \in \mathbb{N}.$$

kernel de função de base radial:

$$k(\mathbf{x}, \mathbf{z}) = \exp\left(-\frac{\|\mathbf{x} - \mathbf{z}\|_2^2}{2\sigma^2}\right), \quad \sigma > 0.$$

$$P(y = 1 \mid \mathbf{x}; \theta) \;=\; \frac{1}{1 + e^{-\theta^T \mathbf{x}}}$$

$$P(y = 1 \mid \mathbf{x}; \theta) \;=\; \frac{1}{1 + e^{-\theta^T \underline{\phi(\mathbf{x})}}}$$

$$\boldsymbol{\theta}^* \;=\; \sum_{i=1}^{n} \alpha_i \, \phi(\mathbf{x}_i)$$

(**Representer Theorem:** *a solução que minimiza o erro pode ser expressa como uma combinação linear das funções de kernel avaliadas nos pontos de treinamento*)

$$\boldsymbol{\theta}^\top \phi(\mathbf{x}) \;=\; \left(\sum_{i=1}^{n} \alpha_i \, \phi(\mathbf{x}_i) \right)^\top \phi(\mathbf{x}) \;=\; \sum_{i=1}^{n} \alpha_i \, \underbrace{\phi(\mathbf{x}_i)^\top \phi(\mathbf{x})}_{k(\mathbf{x}_i, \mathbf{x})}.$$

$$k(\mathbf{x}, \mathbf{z}) \triangleq \phi(\mathbf{x})^\top \phi(\mathbf{z})$$ (define-se $K \in \mathbb{R}^{n \times n}$; ou seja, escolhe-se o kernel)

$$P(y = 1 \mid \mathbf{x}) = \frac{1}{1 + e^{\left(-\sum_{i=1}^{n} \alpha_i \, k(\mathbf{x}_i, \mathbf{x}) + b\right)}}$$

$$k_{\text{lin}}(\mathbf{x}, \mathbf{z}) = \mathbf{x}^\top \mathbf{z}, \quad k_{\text{poly}}(\mathbf{x}, \mathbf{z}) = (\mathbf{x}^\top \mathbf{z} + c)^p, \quad k_{\text{RBF}}(\mathbf{x}, \mathbf{z}) = \exp\left(-\frac{\|\mathbf{x} - \mathbf{z}\|_2^2}{2\sigma^2}\right)$$

$$\min_{\boldsymbol{\alpha}, b} \underbrace{\sum_{i=1}^{n} \ell(y_i, p_i)}_{\text{loss (log-loss / cross-entropy)}} + \underbrace{\frac{\lambda}{2} \boldsymbol{\alpha}^\top K \boldsymbol{\alpha}}_{\text{regularizacao}} \quad \text{com} \quad \ell(y, p) = -y \log p - (1 - y) \log(1 - p)$$